

Idade óssea pediátrica com descritores manuais: comparação de regressores clássicos

Carlos Daniel Reis da Silva, Raul Ferreira Holanda, Rílari Maia Castelo

¹Sistemas de Informação
UniCatólica – Centro Universitário Católica de Quixadá
Quixadá – CE – Brasil

reisdaniel739@gmail.com, raulfholanda@gmail.com
2023010247@unicatolicaquixada.edu.br

Resumo. *Comparamos descritores manuais para estimar idade óssea na base RSNA. Uma amostra de 4.000 imagens recebeu IDs congelados de treino, validação e teste. Três dobras nos 2.800 casos de treino compararam textura, HOG e intensidade, com sexo como covariável. HOG com Gradient Boosting obteve MAE de $22,21 \pm 0,85$ meses na CV e 22,14 nos 600 casos de teste, contra 33,69 da média do treino. Reduzir a resolução da textura de 224 para 128 pixels aumentou o MAE interno em 0,73 mês. Os erros OOF foram maiores nas idades extremas. A independência por paciente não foi verificada.*

Abstract. *We compare handcrafted descriptors for RSNA bone age estimation. A 4,000-image sample received frozen training, validation and test IDs. Three folds within 2,800 training cases compared texture, HOG and intensity, with sex as a covariate. HOG with Gradient Boosting achieved a mean MAE of 22.21 ± 0.85 months in CV and 22.14 on 600 test cases, versus 33.69 for the training-mean baseline. Reducing texture resolution from 224 to 128 pixels increased internal MAE by 0.73 months. OOF errors were larger at the age extremes. Patient independence was not verified.*

1. Introdução

A estimativa de maturidade esquelética em radiografias pediátricas de mão é a tarefa do desafio RSNA [1]. Formulamos a idade óssea, em meses, como regressão a partir da imagem e do sexo. Um baseline com características explícitas permite comparar representações antes de desenvolver modelos mais complexos. As contribuições são:

- amostra auditada e IDs congelados com pré-processamento comum;
- comparação de três famílias e três regressores, com baseline trivial;
- ablação de resolução e análise de previsões fora da dobra (OOF).

2. Trabalhos relacionados

Halabi et al. [1] situam o desafio RSNA, e Larson et al. [2] investigam redes profundas para maturidade esquelética. Nosso estudo privilegia descritores explícitos e não compara diretamente números de protocolos distintos. GLCM [3] e LBP [4] representam textura; HOG [5], desenvolvido para detecção humana, representa gradientes. Sua aplicação à idade óssea é uma hipótese experimental. SVR [6], Random Forest [7] e Gradient Boosting [8] oferecem modelos distintos para a mesma representação. A seleção pela própria CV pode favorecer estimativas otimistas [9]; por isso, distinguimos desenvolvimento de avaliação externa.

3. Metodologia

Dados e protocolo. A versão 2 de `kmader/rsna-bone-age` contém 12.611 imagens, idades de 1 a 228 meses e 5.778 rótulos femininos e 6.833 masculinos. Para limitar o custo, amostramos 4.000 imagens, semente 42, por sexo e faixas $[0, 72)$, $[72, 132)$, $[132, 192)$ e $[192, 240)$ meses. Congelamos 2.800 IDs de treino, 600 de validação e 600 de teste. São divisões do treino público com IDs disjuntos. **Não há chave verificável de paciente:** o protocolo por imagem é provisório e não comprova agrupamento por paciente.

Pixels comuns. Usamos cinza (Pillow L), 224×224 com Lanczos e divisão por 255 em `float32`, sem recorte, remoção de fundo ou realce. A ablação examina essa resolução operacional.

Representações. Textura combina LBP uniforme [4], oito pontos e raio um (histograma de dez valores), com GLCM [3] de 16 níveis, distâncias 1 e 2 e ângulos 0° , 45° , 90° , 135° , simétrica e normalizada. Média e desvio populacional de contraste, dissimilaridade, homogeneidade, energia e correlação nos oito pares produzem dez atributos. HOG [5] usa nove orientações, células 16×16 , blocos 2×2 e normalização L2-Hys (6.084 atributos). Intensidade usa histograma de 32 intervalos em $[0, 1]$, densidade, média, desvio e percentis 25, 50 e 75 (37 atributos). Sexo é acrescentado a todas as famílias; a média adicional do extrator de textura é excluída.

Ajuste e avaliação. Com `scikit-learn` [11], comparamos configurações fixas: SVR RBF ($C = 10$, $\epsilon = 1$, $\gamma = \text{scale}$); RF, 300 árvores, profundidade ilimitada e todas as características; GB, 300 estimadores, profundidade três e taxa 0,05. Árvores usam semente 42. Três dobras estratificadas por idade e sexo, embaralhadas com semente 42, têm 934, 933 e 933 casos. `StandardScaler` é ajustado apenas no treino de cada dobra; o baseline prediz sua média de idades. A seleção pela mesma CV não é avaliação independente [9]. MAE e RMSE medem erro em meses; R^2 mede variação explicada. Reportamos média e desvio amostral entre dobras. O teste registrado usa os mesmos parâmetros, fixados antes do acesso, treino de 2.800 casos e scaler ajustado apenas nele; avalia 600 casos, sem incorporar a validação ao treino final.

A ablação compara textura em 224 e 128 pixels, mantendo GB, sexo e dobras. Código, IDs, parâmetros e resultados: <https://github.com/RaulFH0/tp1-e2-bone-age>. O teste foi publicado por Raul em `e3b12d7`; as figuras usam apenas previsões OOF.




Figura 1. Casos OOF em pixels comuns: dois menores erros e maiores erros nas faixas 0–5 e 16–19 anos. R: referência; P: previsão; E: erro absoluto, em meses.

4. Resultados e discussão

A Tabela 1 distingue a CV de desenvolvimento do teste registrado. HOG+GB, candidato com menor MAE na CV, obteve 22,14 meses no teste, redução de 34,28% contra o baseline de 33,69. O registro informa avaliação única, sem ajuste posterior; não realizamos teste de significância. Na ablação interna, 128 pixels aumentou o MAE em 0,73 mês; diferenças por dobra: 0,01, 1,28 e 0,91.

Tabela 1. CV: MAE médio $\pm$ desvio em três dobras; teste: métricas nos 600 casos. MAE/RMSE em meses; RF: Random Forest; GB: Gradient Boosting.

Família	Modelo	MAE CV	MAE teste	RMSE teste	R^2 teste
Baseline	Média	33,83 $\pm$ 0,99	33,69	40,85	-0,0003
Textura 224	SVR	25,71 $\pm$ 0,41	25,17	32,34	0,373
	RF	24,84 $\pm$ 0,93	24,50	31,39	0,409
	GB	24,81 $\pm$ 0,98	24,16	31,34	0,411
HOG	SVR	28,15 $\pm$ 0,89	27,21	33,96	0,309
	RF	26,73 $\pm$ 0,99	26,36	33,01	0,347
	GB	22,21 $\pm$ 0,85	22,14	28,29	0,520
Intensidade	SVR	28,35 $\pm$ 0,74	26,96	35,15	0,259
	RF	25,76 $\pm$ 1,18	24,73	31,92	0,389
	GB	25,95 $\pm$ 1,04	24,91	32,02	0,385
Textura 128	GB	25,54 $\pm$ 1,51	—	—	—

Nas 2.800 previsões OOF de HOG+GB, Bland–Altman [10] apresenta viés de +0,22 mês e limites descritivos de -55,38 e +55,81 (predito menos referência; média $\pm$ 1,96 DP). O viés pequeno oculta superestimação nas idades menores e subestimação nas maiores (Figura 2); não demonstra concordância clínica.




Figura 2. HOG+GB: Bland–Altman e MAE por faixa, agrupados sobre previsões OOF; barras identificam o número de casos.

5. Conclusão

HOG+GB, selecionado pela CV, alcançou MAE de 22,14 meses no teste registrado; textura favoreceu 224 pixels na ablação interna. Os extremos etários tiveram maior erro e menor representação. Na Figura 1, 3337 tem pouca luminosidade e enquadramento deslocado, mas 4220 também é escuro e apresenta erro pequeno: aparência não estabelece causalidade. A seleção ilustrativa não é aleatória. A ausência de chave de paciente, a amostragem e a escolha pela mesma CV limitam a generalização. São próximos passos esclarecer o agrupamento e avaliar melhorias em outro protocolo, preservando o teste já utilizado de novos ajustes. Estes resultados não validam uso clínico.

Referências

- [1] Halabi, S. S. et al. (2019). The RSNA Pediatric Bone Age Machine Learning Challenge. *Radiology*, 290(2):498–503.
- [2] Larson, D. B. et al. (2018). Performance of a Deep-Learning Neural Network Model in Assessing Skeletal Maturity on Pediatric Hand Radiographs. *Radiology*, 287(1):313–322.
- [3] Haralick, R. M., Shanmugam, K. e Dinstein, I. (1973). Textural Features for Image Classification. *IEEE Trans. Syst., Man, Cybern.*, SMC-3(6):610–621.
- [4] Ojala, T., Pietikäinen, M. e Mäenpää, T. (2002). Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. *IEEE Trans. Pattern Anal. Mach. Intell.*, 24(7):971–987.
- [5] Dalal, N. e Triggs, B. (2005). Histograms of Oriented Gradients for Human Detection. *CVPR*, 1:886–893.
- [6] Smola, A. J. e Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14:199–222.
- [7] Breiman, L. (2001). Random Forests. *Machine Learning*, 45:5–32.
- [8] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- [9] Varma, S. e Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.
- [10] Bland, J. M. e Altman, D. G. (1986). Statistical methods for assessing agreement between two methods of clinical measurement. *The Lancet*, 327(8476):307–310.
- [11] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Apoio de IA. IA generativa auxiliou revisão de código, elaboração de testes, organização do texto e tradução do abstract. Resultados e referências exigem conferência pelos autores; a responsabilidade pela versão submetida permanece com a equipe.