

Idade óssea pediátrica com descritores manuais: comparação interna de regressores clássicos

Carlos Daniel Reis da Silva, Raul Ferreira Holanda

¹Sistemas de Informação

UniCatólica – Centro Universitário Católica de Quixadá
Quixadá – CE – Brasil

reisdaniel739@gmail.com, raulfholanda@gmail.com

Resumo. *Comparamos descritores manuais para estimar idade óssea na base RSNA. Uma amostra de 4.000 imagens recebeu IDs congelados de treino, validação e teste. Três dobras nos 2.800 casos de treino compararam textura, HOG e intensidade, com sexo como covariável. HOG com Gradient Boosting obteve MAE de $22,21 \pm 0,85$ meses, contra $33,83 \pm 0,99$ da média do treino. Na textura, reduzir a resolução de 224 para 128 pixels aumentou o MAE em 0,73 mês. Os erros foram maiores nas idades extremas. Os resultados são internos; a independência por paciente não foi verificada.*

Abstract. *We compare handcrafted descriptors for bone age estimation from RSNA radiographs. A 4,000-image sample received frozen training, validation and test IDs. Three folds within 2,800 training cases compared texture, HOG and intensity, with sex as a covariate. HOG with Gradient Boosting achieved a mean MAE of 22.21 ± 0.85 months, versus 33.83 ± 0.99 for the training-mean baseline. Reducing texture resolution from 224 to 128 pixels increased MAE by 0.73 months. Errors were larger at the age extremes. These are internal results; patient independence was not verified.*

1. Introdução

A estimativa de maturidade esquelética em radiografias pediátricas de mão é a tarefa do desafio RSNA [1]. Formulamos a idade óssea, em meses, como regressão a partir da imagem e do sexo. Um baseline com características explícitas permite comparar representações antes de desenvolver modelos mais complexos. As contribuições são:

- amostra auditada e IDs congelados com pré-processamento comum;
- comparação de três famílias e três regressores, com baseline trivial;
- ablação de resolução e análise de previsões fora da dobra (OOF).

2. Trabalhos relacionados

Halabi et al. [1] situam o desafio RSNA, e Larson et al. [2] investigam redes profundas para maturidade esquelética. Nosso estudo privilegia descritores explícitos e não compara diretamente números de protocolos distintos. GLCM [3] e LBP [4] representam textura; HOG [5], desenvolvido para detecção humana, representa gradientes. Sua aplicação à idade óssea é uma hipótese experimental. SVR [6], Random Forest [7] e Gradient Boosting [8] oferecem modelos distintos para a mesma representação. A seleção pela própria CV pode favorecer estimativas otimistas [9]; por isso, distinguimos desenvolvimento de avaliação externa.

3. Metodologia

Dados e protocolo. A versão 2 de `kmader/rsna-bone-age` contém 12.611 imagens com rótulos `id`, `boneage` e `male`: 5.778 femininos e 6.833 masculinos, de 1 a 228 meses. Para limitar o custo, selecionamos 4.000 imagens, semente 42, estratificadas por sexo e faixas [0, 72), [72, 132), [132, 192) e [192, 240) meses. Congelamos 2.800 IDs de treino, 600 de validação e 600 de teste. São divisões do treino público. IDs de imagem são disjuntos, mas **não há chave verificável de paciente**: o protocolo por imagem é provisório e não comprova o agrupamento exigido pela atividade.

Pixels comuns. Convertemos para cinza (Pillow L), redimensionamos para 224×224 com Lanczos e dividimos por 255 em `float32`. Não aplicamos recorte, remoção de fundo ou realce. A ablação testa essa resolução operacional, sem presumir preservação de todos os detalhes.

Representações. Textura combina LBP uniforme [4], oito pontos e raio um (histograma de dez valores), com GLCM [3] de 16 níveis, distâncias 1 e 2 e ângulos 0° , 45° , 90° , 135° , simétrica e normalizada. Média e desvio populacional de contraste, dissimilaridade, homogeneidade, energia e correlação sobre oito pares produzem mais dez atributos. HOG [5] usa nove orientações, células 16×16 , blocos 2×2 e normalização L2-Hys (6.084 atributos). Intensidade resume a distribuição global: histograma de 32 intervalos em [0, 1], densidade, média, desvio e percentis 25, 50 e 75 (37 atributos). Sexo é acrescentado a todas as famílias; a média adicional do extrator de textura é excluída.

Ajuste e avaliação. Com `scikit-learn` [11], comparamos configurações fixas: SVR RBF ($C = 10$, $\epsilon = 1$, $\gamma = \text{scale}$); RF, 300 árvores, profundidade ilimitada e todas as características candidatas; GB, 300 estimadores, profundidade três e taxa 0,05. Árvores usam semente 42. Três dobras estratificadas por idade e sexo, embaralhadas com semente 42, têm 934, 933 e 933 casos. Cada Pipeline ajusta `StandardScaler` somente no treino interno; o baseline prediz sua média de idades. MAE mede erro absoluto em meses; RMSE destaca erros maiores e R^2 mede variação explicada. Reportamos média e desvio amostral entre dobras. A mesma CV seleciona o candidato; não é avaliação independente [9]. Validação e teste externos não entram nesta execução.

A ablação compara textura em 224 e 128 pixels, mantendo GB, sexo e dobras. Código, IDs, parâmetros, versões e hashes estão em <https://github.com/RaulFH0/tp1-e2-bone-age>. As previsões permitem recomputar as métricas.




Figura 1. Casos OOF em pixels comuns: dois menores erros e maiores erros nas faixas 0–5 e 16–19 anos. R: referência; P: previsão; E: erro absoluto, em meses.

4. Resultados e discussão

A Tabela 1 resume a CV interna. HOG+GB reduz o MAE em 34,35% contra o baseline. Não realizamos teste de significância. A ablação aumenta o MAE em 0,73 mês; diferenças por dobra são 0,01, 1,28 e 0,91 mês, sem generalização a outras famílias.

Tabela 1. CV no treino: média $\pm$ desvio entre três dobras. MAE e RMSE em meses; RF: Random Forest; GB: Gradient Boosting.

Família	Modelo	MAE	RMSE	R^2
Baseline	Média	33,83 $\pm$ 0,99	41,48 $\pm$ 0,66	-0,0001 $\pm$ 0,0001
Textura 224	SVR	25,71 $\pm$ 0,41	33,44 $\pm$ 0,19	0,35 $\pm$ 0,01
	RF	24,84 $\pm$ 0,93	32,16 $\pm$ 1,10	0,40 $\pm$ 0,03
	GB	24,81 $\pm$ 0,98	32,01 $\pm$ 1,34	0,40 $\pm$ 0,04
HOG	SVR	28,15 $\pm$ 0,89	35,37 $\pm$ 0,67	0,27 $\pm$ 0,01
	RF	26,73 $\pm$ 0,99	33,25 $\pm$ 0,89	0,36 $\pm$ 0,02
	GB	22,21 $\pm$ 0,85	28,35 $\pm$ 0,85	0,53 $\pm$ 0,02
Intensidade	SVR	28,35 $\pm$ 0,74	36,69 $\pm$ 0,64	0,22 $\pm$ 0,02
	RF	25,76 $\pm$ 1,18	33,13 $\pm$ 1,60	0,36 $\pm$ 0,05
	GB	25,95 $\pm$ 1,04	33,52 $\pm$ 1,67	0,35 $\pm$ 0,05
Textura 128	GB	25,54 $\pm$ 1,51	32,59 $\pm$ 1,51	0,38 $\pm$ 0,04

Nas 2.800 previsões OOF de HOG+GB, Bland–Altman [10] apresenta viés de +0,22 mês e limites descritivos de -55,38 e +55,81 (predito menos referência; média $\pm$ 1,96 DP). O viés pequeno oculta superestimação nas idades menores e subestimação nas maiores (Figura 2); não demonstra concordância clínica.




Figura 2. HOG+GB: Bland–Altman e MAE por faixa, agrupados sobre previsões OOF; barras identificam o número de casos.

5. Conclusão

HOG+GB estabeleceu o menor MAE interno; textura favoreceu 224 pixels. Os extremos etários tiveram maior erro e menor representação. Na Figura 1, 3337 tem pouca luminosidade e enquadramento deslocado, mas 4220 também é escuro e apresenta erro pequeno: aparência não estabelece causalidade. A seleção ilustrativa não é aleatória. A ausência de chave de paciente, a amostragem e a escolha pela mesma CV limitam a generalização. São próximos passos esclarecer o agrupamento, consolidar a avaliação externa da equipe e testar melhorias sem reutilizar o teste para seleção. Estes resultados não validam uso clínico.

Referências

- [1] Halabi, S. S. et al. (2019). The RSNA Pediatric Bone Age Machine Learning Challenge. *Radiology*, 290(2):498–503.
- [2] Larson, D. B. et al. (2018). Performance of a Deep-Learning Neural Network Model in Assessing Skeletal Maturity on Pediatric Hand Radiographs. *Radiology*, 287(1):313–322.
- [3] Haralick, R. M., Shanmugam, K. e Dinstein, I. (1973). Textural Features for Image Classification. *IEEE Trans. Syst., Man, Cybern.*, SMC-3(6):610–621.
- [4] Ojala, T., Pietikäinen, M. e Mäenpää, T. (2002). Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. *IEEE Trans. Pattern Anal. Mach. Intell.*, 24(7):971–987.
- [5] Dalal, N. e Triggs, B. (2005). Histograms of Oriented Gradients for Human Detection. *CVPR*, 1:886–893.
- [6] Smola, A. J. e Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14:199–222.
- [7] Breiman, L. (2001). Random Forests. *Machine Learning*, 45:5–32.
- [8] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- [9] Varma, S. e Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.
- [10] Bland, J. M. e Altman, D. G. (1986). Statistical methods for assessing agreement between two methods of clinical measurement. *The Lancet*, 327(8476):307–310.
- [11] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Apoio de IA. IA generativa auxiliou revisão de código, elaboração de testes, organização do texto e tradução do abstract. Resultados e referências exigem conferência pelos autores; a responsabilidade pela versão submetida permanece com a equipe.